## Actividad Redes Neuronales Profundas Ejercicio 2

## Mario Alberto Castañeda Martínez - A01640152

En este segundo ejercicio, se creará un modelo de redes neuronales profundas para el dataset Fashion\_nmist de Tensorflow. Se probarán diferentes modificaciones del modelo para encontrar el mejor accuracy posible.

Primero se importan las librerías necesarias:


```
import tensorflow as tf
from tensorflow.keras import datasets, layers, models
import matplotlib.pyplot as plt
import numpy as np
```

Se carga el dataset y se definen los conjuntos de entrenamiento y de prueba:

```
#prepara dataset Fashion_mnist
(train_images, train_labels), (test_images, test_labels) = datasets.fashion_mnist.load_data()
#normalizar
train_images, test_images = train_images / 255.0, test_images/255
```

Se definen las clases del dataset y se muestran en sus respectivas imágenes:

```
class_names = ['T-shirt/top', 'Trouser', 'Pullover', 'Dress', 'Coat', 'Sandal', 'Shirt', 'Sneaker', 'Bag', 'Ankle boot']
plt.figure(figsize=(10,10))
for i in range (10):
   plt. subplot(5,5,i+1)
   plt.xticks([])
   plt.yticks([])
   plt.grid(False)
   plt.imshow(train_images[i])
   plt.xlabel(class_names[train_labels[i]])
plt.show()
```



Se agregan capas de convolución, filtros y la función de activación:

En este caso, solo se agregaron dos capas porque con dos capas se consigue un accuracy alto y al haber realizado pruebas con 3 capas, se sigue consiguiendo el mismo accuracy e incluso en ocasiones, se obtenía un accuracy un poco menor.

```
#Capas de convolución
model = models.Sequential()
model.add(layers.Conv2D(32, (3,3), activation='relu', input_shape=(28, 28, 1))) # el input_shape se refiere a la entrada de las imagenes, 28x28 pixeles, un canal de color
model.add(layers.MaxPooling2D((2, 2)))
model.add(layers.Conv2D(64, (3, 3), activation='relu'))
model.add(layers.MaxPooling2D((2, 2)))
model.summary()
```

Model: "sequential\_10"

Layer (type)	Output Shape	Param #
conv2d_28 (Conv2D)	(None, 26, 26, 32)	320
<pre>max_pooling2d_19 (MaxPooli ng2D)</pre>	(None, 13, 13, 32)	0
conv2d_29 (Conv2D)	(None, 11, 11, 64)	18496
<pre>max_pooling2d_20 (MaxPooli ng2D)</pre>	(None, 5, 5, 64)	0
Total params: 18816 (73.50 K Trainable params: 18816 (73. Non-trainable params: 0 (0.0	50 KB)	

Se agrega la parte de aplanamiento de la salida de las capas convolucionales, para después agregar uan capa densa con 128 neuronas con activación Relu y una capa de salida con activación sigmoide:

```
model.add(layers.Flatten())
model.add(layers.Dense(128, activation='relu'))
model.add(layers.Dense(10, activation ='sigmoid'))
model.summary()

Model: "sequential_10"
```

Layer (type)	Output Shape	Param #	
conv2d_28 (Conv2D)	(None, 26, 26, 32)	320	
<pre>max_pooling2d_19 (MaxPooli ng2D)</pre>	(None, 13, 13, 32)	0	
conv2d_29 (Conv2D)	(None, 11, 11, 64)	18496	
<pre>max_pooling2d_20 (MaxPooli ng2D)</pre>	(None, 5, 5, 64)	0	
flatten_9 (Flatten)	(None, 1600)	0	
dense_18 (Dense)	(None, 128)	204928	
dense_19 (Dense)	(None, 10)	1290	
Total params: 225034 (879.04 KB) Trainable params: 225034 (879.04 KB) Non-trainable params: 0 (0.00 Byte)			

Se compila el modelo, en este caso se entrena en 20 épocas y se agrega el conjunto de validación.

model.compile(optimizer='adam',loss=tf.keras.losses.SparseCategoricalCrossentropy(from\_logits=True),metrics=['accuracy'])
history = model.fit(train\_images, train\_labels, epochs=20, validation\_data=(test\_images, test\_labels))

```
Epoch 1/20
Epoch 2/20
Epoch 3/20
Epoch 5/20
Epoch 6/20
Epoch 8/20
Epoch 9/20
Epoch 10/20
Epoch 11/20
Epoch 12/20
Epoch 14/20
Epoch 15/20
Epoch 16/20
Epoch 17/20
Epoch 18/20
Epoch 19/20
Epoch 20/20
```

Después de generar el modelo, se visualiza el accuracy con los datos de entrenamiento y el accuracy para nuevas imágenes.

```
plt.plot(history.history['val_accuracy'], label = 'val_accuracy')
plt.xlabel('Epoch')
plt.ylabel('Accuracy')
plt.ylim([0.5, 1])
plt.legend(loc='lower right')
test_loss, test_acc = model.evaluate(test_images, test_labels, verbose=2)
     313/313 - 2s - loss: 0.5242 - accuracy: 0.9103 - 2s/epoch - 5ms/step
        1.0
        0.9
        0.8
        0.6
                                                                accuracy
                                                                val_accuracy
         0.5
                      2.5
                              5.0
                                     7.5
                                            10.0
                                                    12.5
               0.0
                                                            15.0
                                                                   17.5
```

Epoch

plt.plot(history.history['accuracy'], label='accuracy')


print(test\_acc)

0.9103000164031982

Este accuracy obtenido indica que el modelo es muy bueno para pronosticar nuevas imágenes, cabe destacar que durante las diferentes pruebas de modelos, el accuracy siempre se mantenía entre el 90 y el 91% de accuracy. Se debe igualmente señalar que los modelos en general indicaban un cierto sobreajuste para los datos o imágenes de entrenamiento, a pesar de esto, se logró encontrar un modelo con un accuracy para nuevas imágenes muy bueno. Es importante recalcar que se probaron distintas modificaciones del modelo (más filtros, menos neuronas, menos épocas) y en general los resultados siempre eran del 90%, con el modelo actual, se logró alcanzar un accuracy del 91%.

Se prueba el modelo con una imagen:

```
n=5002 ##Number of image
plt.figure(figsize=(2,2))
plt.imshow(test_images[n])
plt.xlabel(class_names[test_labels[n]])
plt.show()
```



El modelo es capaz de identificar la imagen correctamente.